

Warszawa, 19 listopada 2018

# Metody ewolucyjne i uczenie się maszyn

## Projekt 2 Specyfikacja

Na jednym z benchmarków dot. modelowania szeregów czasowych (np. NN3 lub M3) porównać metodę xgboost z modelem liniowym.

Prowadzący:  
dr inż. Paweł Zawistowski

Wykonali:  
Michał Kruszewski, Łukasz Błaszka

# Spis treści

1.	Cel . . . . .	3
2.	Założenia . . . . .	3
3.	Krótki wstęp teoretyczny . . . . .	3
	3.1. ARIMA . . . . .	3
	3.2. Metoda xgboost . . . . .	3
4.	Zbiór danych . . . . .	4
5.	Prezentacja wyników . . . . .	5

## 1. Cel

Celem projektu jest praktyczne poznanie dowolnie wybranego modelu liniowego oraz metody xgboost, stosowanych do modelowania szeregów czasowych. Realizacja celu oparta będzie na porównaniu obu metod na jednym z benchmarków dotyczących modelowania szeregów czasowych (NN3 lub M3).

## 2. Założenia

- Zadanie rozwiązane zostanie w języku *R*.
- Jako benchmark testowy wybrany został nowszy benchmark NN3. Zawiera on mniej szeregów czasowych niż benchmark M3 (111 vs 3003), dlatego lepiej nadaje się do celów dydaktycznych (subiektywna ocena osób realizujących projekt).
- Jako model liniowy wybrany został popularny model ARIMA (*ang. Autoregressive Integrated Moving Average*), uznawany za jedną z opcji do modelowania szeregów niestacjonarnych.
- W celu dopasowania najlepszego modelu ARIMA wykorzystana zostanie metoda *auto.arima* pochodząca z pakietu *forecast*.
- W celu predykcji metodą xgboost wykorzystana zostanie biblioteka *xgboost* (<https://github.com/dmlc/xgboost>).
- Ze względu na brak jakiegokolwiek doświadczenia z metodą xgboost, oraz liczbę jej parametrów, sposób optymalizacji określony zostanie na etapie implementacji.

## 3. Krótki wstęp teoretyczny

### 3.1. ARIMA

Model ARIMA jest rozszerzeniem modelu ARMA, który poddawany jest różnicowaniu w celu usunięcia trendu. Model ARMA(p,q) dla stacjonarnego szeregu czasowego  $z_t$  ma postać:

$$z_t = \phi_1 z_{t-1} + \dots + \phi_p z_{t-p} + w_t + \psi_1 w_{t-1} + \dots + \psi_q w_{t-q} \quad (1)$$

gdzie  $z_t$  jest szeregiem stacjonarnym o zerowej średniej,  $\phi_i, \psi_i \in \mathbb{R} (\phi_p \neq 0, \psi_q \neq 0)$ , a  $w_i \sim N(0, \sigma^2)$ .


Różnicowanie potrzebne jest do osiągnięcia stacjonarności szeregu i polega na zastąpieniu szeregu czasowego  $z_t$  nowym szeregiem czasowym  $z'_t$  takim że:

$$z'_t = \nabla z_t = z_t - z_{t-1} \quad (2)$$


### 3.2. Metoda xgboost

Metoda xgboost (*Extreme Gradient Boosting*) wywodzi się z metody GBM (*ang. Gradient Boosting Machine*). Obie te metody opierają się o gradientowe wzmacnianie drzew (*ang. gradient boosted trees*). U ich podstaw znajduje się model zespołu drzew decyzyjnych (*ang. decision tree ensembles*). W zespole takim pojedyncze drzewo zazwyczaj słabo radzi sobie z klasyfikacją/regresją, dlatego do predykcji wykorzystywany jest cały zespół drzew. Idea wzmacniania gradientowego polega na tworzeniu ciągu prostych drzew, z których każde kolejne jest zbudowane do predykcji reszt generowanych przez poprzednie.


Różnica w idei działania xgboost a GDM jest niewielka. xgboost używa bardziej regularnej formalizacji modelu w celu kontroli przeuczenia (*over-fitting*). Dodatkowo xgboost jest mocno zoptymalizowany w obszarach szybkości obliczeń oraz zużycia pamięci.




(a) Dane zaszumione



(b) Dane zaszumione



(c) Trend



(d) Wahania okresowe

Rysunek 1: Przykładowe szeregi czasowe z benchmark'u NN3.

## 4. Zbiór danych

Liczba szeregów czasowych znajdujących się w benchmark'u NN3 wynosi 111. Długość wektora testowego dla każdego z szeregów wynosi 18. Zbiór danych jest zaczerpnięty z jednorodnej populacji empirycznych biznesowych szeregów czasowych. Wśród danych dominują szeregi, które wydają się być mocno zaszumione (rys. 1a, 1b). Znaleźć tam również można szeregi czasowe z wyraźnym trendem (rys. 1c) lub wahaniem okresowymi (rys. 1d).

## 5. Prezentacja wyników

Porównanie modelu ARIMA z metodą xgboost dokonane zostanie na podstawie przebiegu funkcji gęstości prawdopodobieństwa względnych błędów. Wartości błędów nie będą uśredniane dla poszczególnych szeregów, co oznacza, że długość wektora błędów dla którego zostanie przedstawiony przebieg funkcji gęstości prawdopodobieństwa wynosić będzie  $111 \times 18 = 1998$ .

Zagregowana funkcja gęstości prawdopodobieństwa błędów może ukrywać niektóre właściwości stosowanych modeli, dlatego zostanie ukazany również, na wspólnym wykresie, przebieg błędów dla wszystkich szeregów czasowych.

Wyniki strojenia parametrów metody xgboost zaprezentowane zostaną w analogiczny sposób. Dodatkowo zamieszczone mogą zostać fragmenty wydruków stosowanych funkcji, niosące wartościowe informacje.